

中国高科

CHINA HI-TECH GROUP

网络数据采集实践

实施方案

教学内容

- 第一节 课程介绍
- 第二节 组队安排
- 第三节 候选项目介绍
- 第四节 实训安排
- 第五节 实训产出

课程介绍

- 《网络数据采集实践》是《数据采集与数据预处理》课程的后续实践性课程，是一门独立开设的实践性课程。
- 《网络数据采集实践》的主要目标如下：
 1. 以“项目驱动、实战赋能”为核心，旨在通过沉浸式项目实训，帮助学生贯通数据采集与预处理的理论知识与工程实践，将抽象原理转化为解决实际问题的能力。
 2. 学生将逐步掌握主流数据采集方法与工具，提升动手实践与技术创新能力。
 3. 课程引导学生树立正确的数据伦理观与法治观念，强调数据采集的合法性、合规性与社会责任，培养其网络安全意识与信息素养。

组队安排

组号	学号	姓名
第1组		
第2组		
第3组		
第4组		
第5组		

组号	学号	姓名
第6组		
第7组		
第8组		
第9组		
第10组		

候选项目介绍

□ 选题要求

1. 分组选题，每组3~5人（**建议5人**），每组选取一题，也可自拟符合要求题目。
2. **每题只能被1个组选中。**
3. 选题确定后，由组内成员指定小组长，并进行分工，组织大家共同完成课程设计。

□ 项目清单如下：

1. 题目1：股票行情信息采集与分析项目
2. 题目2：招聘岗位信息采集与分析项目
3. 题目3：二手房交易信息采集与分析项目
4. 题目4：网络舆情热点采集与分析项目
5. 题目5：社交媒体话题采集与分析项目
6. 题目6：电商商品评价采集与分析项目
7. 题目7：图书信息采集与分析项目
8. 题目8：音乐榜单采集与分析项目
9. 题目9：体育赛事数据采集与分析项目
10. 题目10：航班信息采集与分析项目
11. 题目11：餐饮美食评价采集与分析项目
12. 题目12：能源价格采集与分析项目
13. 题目13：外汇汇率采集与分析项目
14. 题目14：视频热度排行采集与分析项目
15. 题目15：物流快递信息采集与分析项目

候选项目介绍：01 股票行情信息采集与分析



基于真实交易软件界面的数据映射，实现从K线走势、成交量到技术指标的全维度自动化采集与监控，精准还原市场脉搏，为量化决策提供可靠支撑。

参考网站: <https://quote.eastmoney.com/>

项目背景：从人工盯盘到智能聚合

针对金融市场数据碎片化、人工整理效率低的痛点，通过自动化技术汇聚东方财富网等主流平台的实时与历史行情，构建结构化数据集，高效捕捉稍纵即逝的市场信号，揭示内在运行规律。



自动化采集与预处理

定期抓取多源数据，自动清洗冗余信息，完成数据归一化，保障数据准确性与一致性。



多维度深度分析

自动计算MA、MACD等关键技术指标，深度挖掘量价关系、波动性与相关性，识别市场趋势。



趋势与对比洞察

涵盖时间序列价格走势、个股与大盘对比，以及行业板块资金流向与涨跌幅排名分析。



信号研判与可视化

智能识别金叉死叉、超买超卖状态，自动生成可视化分析报告，为投资决策提供直观依据。

候选项目介绍：02 招聘岗位信息采集与分析



项目背景与价值

就业市场瞬息万变，传统调研已难捕捉全貌。本项目通过自动化采集主流平台岗位数据，构建结构化信息库，直观呈现行业需求热点、区域薪资差异与技能偏好，为求职者、企业及高校提供精准的决策支撑。

参考网站: <https://www.51job.com/>

+ 自动化数据采集

建立自动抓取引擎，定期从51job、智联招聘等主流平台获取海量岗位信息，替代传统人工收集，提升数据覆盖面与时效性。

多维深度分析

挖掘行业需求热度、薪资结构分布、技能关键词频率，识别新兴职位趋势与地域需求差异，形成全方位的市场洞察。

数据解析与预处理

利用NLP技术清洗与结构化处理非标准化文本，精准提取岗位名称、薪资范围、工作地点、核心技能等关键业务字段。

可视化决策报告

将枯燥数据转化为直观的图表与词云，输出行业趋势、薪资地图与技能图谱报告，为人才培养和职业规划提供可视化依据。

候选项目介绍：03 二手房交易信息采集与分析



项目背景

在“房住不炒”的政策基调下，二手房市场信息庞杂且瞬息万变。项目通过自动化技术采集链家等平台房源数据，经清洗与归一化处理，深度挖掘价格形成机制，为购房者、中介机构及监管部门提供科学、动态的数据决策支撑。

核心功能模块



自动化数据采集

构建多源数据抓取引擎，定期自动采集目标城市的二手房挂牌信息，保障数据时效性与全面性。



数据解析与预处理

智能提取户型、面积、朝向等关键特征，清洗异常值与重复数据，建立标准化、高质量的房源数据库。



多维度关联分析

深入分析房价的空间分布规律、时间演变趋势，量化房屋属性与价格的内在关联，挖掘市场潜在逻辑。




可视化报告生成

自动生成房价热力地图、价格走势曲线等可视化图表，输出多维度分析报告，直观呈现市场动态。

通过对价格趋势、空间分布、房源特征及市场活跃度的全景洞察，实现对二手房市场的精准监测，为各方主体提供客观、科学的决策依据。

候选项目介绍：04 网络舆情热点采集与分析



基于社交媒体与新闻平台的实时数据采集，结合自然语言处理技术，实现对网络舆论热点的全天候追踪与深度情感洞察，为决策提供科学依据。

参考网站: <https://news.sina.com.cn/>

项目背景：自媒体时代舆论传播呈现碎片化、即时化特征，传统分析手段滞后。项目通过自动化采集与NLP技术，追踪热点演变，精准洞察公众情绪，为舆情引导和危机公关构建高效情报支持体系。



自动化数据采集

定时抓取多平台头条与评论数据，覆盖主流新闻与社交媒体渠道，确保数据源的全面性。



文本解析与预处理

通过NLP技术进行文本清洗、分词与关键词提取，剔除噪音数据，为深度分析奠定基础。



多维度舆情分析

开展热点发现、情感倾向判定及传播路径溯源，全方位解析舆论形成机制与发展态势。



可视化报告生成

自动输出热点榜单、情感趋势图及传播节点图谱，以直观图表辅助快速决策与研判。

候选项目介绍：05 社交媒体话题采集与分析



以微博热搜榜为核心数据源，实时抓取海量碎片化信息，直观呈现公共议题的动态演变过程。

针对社交媒体信息流碎片化、人工提炼困难的痛点，项目通过自动化技术采集话题数据，解析文本与互动指标，清晰展现话题热度周期、地域分布及关键传播节点，为品牌营销和舆论研究提供科学、量化的决策依据。



自动化数据采集

实时或定时抓取微博热门话题榜及关联博文，覆盖海量信息流，确保数据时效性与完整性。



数据解析与预处理

智能提取话题名称、阅读/讨论量、互动数据等关键信息，清洗噪声数据，构建标准化数据集。



多维话题深度分析

分析话题热度趋势、传播圈层及情感倾向，识别关键传播节点与意见领袖，洞察用户参与特征。



可视化报告生成

自动输出热度榜单、传播路径图及用户画像报表，以直观图表呈现分析结果，辅助快速决策。

候选项目介绍：06 电商商品评价采集与分析

评价 · 13

匿名买家

2026-04-10 已购: 3斤 / 10mm[新鲜蓝莓葡萄]

这个简直太酸了，真心建议别买，纯坑人的，起个蓝莓葡萄的名，就是很酸的那种小葡萄，差评！！！！！！！！



项目背景：从海量声音中沉淀价值

电商用户评价是消费者真实体验的核心载体，也是品牌改进的第一手资料。针对热门商品评价数量庞大、人工分析效率低的痛点，本项目通过自动化采集与NLP文本分析技术，量化情感倾向、挖掘核心诉求，为产品迭代与精细化运营提供数据支撑。

核心功能：全流程自动化处理闭环



自动化数据采集

批量抓取京东等主流电商平台指定商品的全量用户评价，支持多维度筛选与增量更新。



智能清洗与预处理

对评论文本进行去噪、分词、去停用词处理，剔除无效信息，为后续分析建立高质量语料库。



深度NLP文本分析

运用情感分析、主题提取与TF-IDF算法，量化用户情感倾向，识别高频提及的产品属性与服务关键词。



可视化洞察报告

自动生成口碑趋势、关注点分布及负面痛点归因报告，以图表化形式直观呈现分析结果。

从“总体口碑、用户关注、负面反馈、时效变化”四大维度切入，为品牌优化产品设计、改善服务体验提供科学依据。

参考网站: <https://www.jd.com/>

候选项目介绍：07 图书信息采集与分析



基于真实书店场景与线上全平台数据的深度融合，为阅读市场提供客观、精准的量化洞察，连接读者需求与出版供给。

参考网站: <http://book.dangdang.com/>

在全民阅读的浪潮下，图书市场信息繁杂且分散。本项目通过自动化技术抓取当当等主流平台的图书元数据与用户互动数据，深度解析品类分布、价格策略与畅销逻辑，为读者挖掘优质读物，同时为出版社优化选题方向、书店调整备货策略提供科学的数据支撑。

核心功能体系

实现图书全量信息的自动化采集与清洗，统一分类标准；构建多维度分析模型，智能生成可视化的市场概览与趋势报告，让数据处理从繁琐的人工操作转向高效的智能分析。

关键分析维度

涵盖品类份额、价格与折扣分布、高价值作者/出版社排行及评分口碑特征分析。通过交叉对比，精准定位市场热点与读者偏好，揭示畅销书背后的核心驱动因素。

候选项目介绍：08 音乐榜单采集与分析



以网易云音乐为核心数据源，覆盖TOP500、飙升榜、新歌榜等全维度榜单入口，构建完整的音乐数据采集体系。

参考网站: <https://music.163.com/>

项目背景：数据驱动的音乐市场洞察

数字音乐时代，榜单是大众审美晴雨表，但人工记录效率低。项目通过自动化采集多平台榜单，构建数据库，揭示流行周期与歌手影响力变迁，为宣发与推荐提供科学依据。



自动化数据采集

定期抓取主流音乐平台榜单，实现数据的实时同步与增量更新，覆盖歌曲基础信息与榜单排名数据。



数据清洗与标准化

对采集数据进行去重、纠错，统一歌手、专辑与音乐风格标签，构建结构规范、可复用的音乐元数据池。



多维趋势深度分析


聚焦榜单动态、风格占比与歌手影响力，挖掘音乐流行规律，输出可视化的趋势分析与关联性洞察报告。



用户互动价值挖掘

关联分析播放、评论、分享等用户行为数据，量化音乐作品的市场反馈，辅助评估宣发效果与受众偏好。

候选项目介绍：09 体育赛事数据采集与分析



本项目聚焦海量体育赛事数据的自动化采集与深度解析，将非结构化的赛事信息转化为标准化数据资产。通过对攻防特征、联赛格局及球员价值的多维挖掘，为战术复盘、媒体传播和竞技训练提供科学、直观的数据支撑，让比赛细节“有据可依”。

核心功能体系

自动化全域采集

多源抓取赛程、赛果、积分榜及球员技术统计，覆盖主流联赛数据，保障数据源的全面性与时效性。

数据清洗与标准化

统一不同平台统计口径，智能补全缺失数据，过滤异常值，构建高质量、结构化的赛事数据库。


多维深度价值分析

深度挖掘联赛竞争格局、球队攻防效率及球员综合能力，量化比赛关键事件影响，输出专业分析结论。

可视化报告输出

自动生成攻防雷达图、积分榜趋势、球员能力矩阵等可视化报告，直观呈现数据洞察，提升传播效率。

候选项目介绍：10 航班信息采集与分析



依托机场实时数据大屏与主流票务平台接口，构建多源异构航空信息采集体系，精准捕捉航班动态与价格波动，为旅客与航司提供双向数据支撑。

项目背景：破解信息不对称难题

针对航班时刻与票价的强实时性、高波动性特征，解决人工比价成本高、数据获取难的痛点。通过自动化手段采集全量数据，构建标准化航空出行数据集，挖掘票价规律与准点特征，实现科学出行规划与收益管理辅助。



全流程数据能力

实现航班信息的自动化抓取、清洗与结构化存储；构建时间序列数据模型，自动生成可视化的价格走势与准点率分析报告，提升数据利用效率。



多维价值分析视角

深度解析票价波动周期、航线热度排名与季节性规律；横向对比不同航司、机型的准点率与服务水平，为用户提供决策依据，为航司优化运营提供参考。

候选项目介绍：11 餐饮美食评价采集与分析



基于大众点评等平台的真实用户评价数据采集与
可视化展示

参考网站: <https://www.dianping.com/>

项目背景：挖掘海量数据价值，洞察市场先机

本地生活服务平台沉淀了海量餐厅评价数据，是消费者决策和行业洞察的宝贵资源。针对新店涌现、评价更新快的特点，本项目通过采集与分析，为消费者和创业者提供精准的市场情报与决策支持。

自动化数据采集

基于网络爬虫技术，定期抓取多城市餐厅基础信息与实时用户评价，确保数据时效性与全面性。

智能解析与预处理

清洗去噪统一菜系分类，利用NLP技术进行情感倾向分析，提炼好评与差评的核心关键词特征。

多维餐饮市场分析

深度剖析菜系热度排行、人均消费价格分布及口碑画像，挖掘市场空白点与热门赛道机会。

可视化报告生成

自动生成城市餐饮热力地图、商圈特色分析等可视化报告，直观呈现数据价值，辅助商业决策。

候选项目介绍：12 能源价格采集与分析



通过高精度图像识别与网络爬虫技术，实时捕捉加油站电子价牌与大宗商品交易数据，构建多源异构数据融合体系，为能源价格的趋势研判与决策支持提供真实、可靠的一手信息源。

项目背景：从“被动接收”到“主动研判”

针对能源价格信息分散、更新滞后、人工追踪效率低的痛点，本项目建立自动化采集与分析体系，整合原油、成品油、天然气全品类价格数据，深挖季节特征、区域价差与调价规律，为物流企业成本核算、车主出行规划及行业研究提供科学支撑。



核心功能体系

实现原油、成品油等数据的自动化抓取与预处理，构建完整的价格时间序列；基于时序分析算法，挖掘价格走势、周期性波动特征，并自动生成可视化的调价周期与趋势分析报告。



多维价值洞察

从国际国内价格联动、区域零售价差、调价频率与幅度等维度切入，关联分析能源价格与股市、通胀指标的深层逻辑，为不同用户群体提供差异化、高价值的决策参考依据。

价值主张：为物流企业、私家车主及行业研究者提供精准、及时、系统的能源价格决策支持服务

参考网站: <https://www.cngold.org/>

候选项目介绍：13 外汇汇率采集与分析



通过实时抓取银行间外汇牌价，构建标准化数据库，消除手工查询的时滞性。为涉外企业财务决策与个人换汇规划提供科学依据，规避汇率波动带来的潜在风险。

01 / 项目背景与价值

针对银行报价来源分散、人工整理效率低的痛点，建立自动化采集与分析系统。聚焦主要货币对的走势、波动率及套利空间，为跨境贸易、投资提供全方位的数据洞察。



自动化数据采集

定时抓取多家银行官方发布的外汇牌价，覆盖主要币种，确保数据源真实、及时。



多维度深度分析

计算波动率、相关性等衍生指标，结合历史数据挖掘套利机会，为决策提供量化支持。



数据清洗与预处理

统一数据格式，按时间戳对齐多源数据，剔除异常值，构建高质量的标准化分析库。



可视化智能报告

自动生成走势图表、波动率热力图等可视化报告，直观呈现汇率变化规律与风险点。

候选项目介绍：14 视频热度排行采集与分析



电视剧/2023/古装 武侠/张云龙 陈...
建文三年，鸡鹅巷的小贼李雾见济南府金事王克恭携万贯家财平调进入...

更新至4集



阿凡达：水之道 ▲ 478%

5281条弹幕 新增评论超1000

电影/2022/动作 科幻/佐伊·索尔达...
影片设定在《阿凡达》的剧情落幕十余年后，讲述了萨利一家（杰克、...



喜欢你我也是第4季 ▲ 443%

1854条弹幕 昨天上新

综艺/2023/观察 情感/官鸿 蒋诗萌...
《喜欢你我也是》第四季青年社交观察恋爱爽综，为大家继续谱写浪漫...

实时抓取视频平台热播榜单，直观呈现多品内容热度排名，为数据采集与趋势研判提供真实样本。

参考网站: <https://www.iqiyi.com/>

项目背景：针对在线视频热度瞬息万变、人工追踪困难的痛点，通过自动化采集爱奇艺等主流平台榜单数据，系统解析爆款内容爬升模式、题材受众基本盘及口碑热度关联，为内容制作选题与平台运营策略提供科学的决策支撑。



自动化数据采集

定期定点抓取多平台热度榜单与作品详情，覆盖剧集、电影、综艺全品类，实现数据的持续化沉淀。



数据解析与清洗

对采集数据进行结构化清洗，统一题材标签、标准化热度数值，剔除无效干扰信息，确保分析基础准确。



多维热度分析模型


构建全维度分析体系，涵盖热度生命周期、题材受众分布、评分与热度相关性，挖掘爆款背后的核心逻辑。



可视化决策报告

自动生成动态热度榜单、题材趋势图谱及要素关联报表，以直观图表形式输出分析结论，辅助快速决策。

候选项目介绍：15 物流快递信息采集与分析



项目背景：让物流决策有据可依

物流快递是国民经济“大动脉”，但价格时效信息分散、更新频繁，用户凭经验决策效率低。本项目通过自动化采集主流平台数据，构建标准化物流信息数据集，系统分析线路运费差异与价格波动规律，为个人寄件和商家物流选型提供科学的决策支持，实现降本增效。



核心功能：全流程数据化闭环

01 采集与预处理

定期抓取运费与时效数据，清洗冗余信息，构建标准的“线路-重量-价格”结构化数据库。

02 分析与可视化输出

深度挖掘运费差异与时效规律，自动生成直观的线路对比图、时效分析报告，辅助快速决策。



分析维度：多视角评估物流价值

多维数据对比分析

横向对比不同快递公司的运费定价策略、平均运输时效及稳定性，量化成本与效率的平衡。

服务与覆盖全景洞察

结合网络覆盖范围、服务深度及用户真实评价，全方位评估物流服务商的综合服务质量。

候选项目介绍

□ 以上项目均需实现如下功能：

1. 定期采集数据并保存至HDFS
2. 网页信息解析与预处理，提取关键信息，以预设格式保存至本地；
3. 关键信息处理与分析，完成数据预处理（归一化、缺失值处理），输出数据统计；
4. 数据可视化，制作数据分析报告（PPT，不少于5页内容）。

□ 除以上介绍项目，同学们亦可自拟题目，但需与指导老师确认后再开展。

实训安排

- 根据所学的数据采集与数据预处理的知识，开发网络数据采集的开发工程项目，要求包括：数据采集、数据解析、数据存储、数据分析与可视化。
- 具体内容如下：
 1. 开发背景及课题分析
 2. 项目需求分析
 3. 项目开发设计
 4. 项目开发实施
 5. 项目测试实施
 6. 文档撰写

实训安排 (计科)



Day1-2

- ✓ 组队/分工
- ✓ 选题
- ✓ 要求

Day3-5

- ✓ 环境准备
- ✓ 项目实施

Day6-8

- ✓ 项目实施
- ✓ 课程设计报告
- ✓ 数据分析报告
- ✓ 中期检查

Day9-10

- ✓ 课程设计报告
- ✓ 数据分析报告
- ✓ 答辩

□ 实训完成后提交内容：

1. 课程设计报告
2. 数据分析报告
3. 项目代码包
4. 答辩视频（5分钟以内）
5. 项目成员表现评分（组长，含组长自己）

□ 上交要求：将这些电子文档形成一个压缩文件，文件名为：**年级专业班级-组号-项目名称-学号-姓名**（仅填写组长学号姓名），发送至指导教师的QQ邮箱。

答辩视频内容

□ 答辩视频内容主要从以下几方面展开：

1. 项目组成员介绍及工作职责
2. 数据分析报告汇报
3. 代码结构（项目基本结构和核心代码）
4. 项目过程遇到的问题及解决办法分享

• THANKS FOR YOUR TIME

保密条款和免责声明

本推介材料是由中国高科集团股份有限公司XX部编制，仅在保密前提下向特定对象提供。阁下阅读本推介材料，即表明阁下同意对本推介材料及其他文件中披露的信息予以绝对保密，请不要以任何目的将这些信息，无论全部或部分，复制、转发、披露给其他任何人或直接出版。

本推介材料包含一些前瞻性陈述，这些陈述含有假设、风险和不确定性。基于此，我们不能向阁下保证这些统计信息在任何特定条件下都是准确、适当和完整的，亦不能保证这些统计信息以及据以得出这些信息的假设能够反映或代表中国高科集团股份有限公司及所属公司。